arXiv :1903.09766v 3 [cs.CV] 2020年2月9日

快速水下图像增强技术提升视觉感知能力

Md Jahidul Islam [1]、Youya Xia [2]和Junaed Sattar [3]

1 islam034， 2 xiaxx244， [3] junaed}@umn.edu

美国明尼苏达州双子城明尼苏达大学计算机科学与工程系交互式机器人与视觉实验室，明尼苏达机器人研究所

摘要

本文提出了一种基于条件生成对抗网络的实时水下图像增强模型。为监督对抗训练过程，我们构建了评估感知图像质量的目标函数，该函数综合考量图像全局内容、色彩特征、局部纹理及风格信息。同时我们发布了EUVP ——一个包含配对与非配对水下图像的大规模数据集，这些图像涵盖“低质量”与“高质量”两类样本，均通过七种不同摄像机在海洋探索及人机协作实验中不同能见度条件下采集。通过多项定性与定量评估表明，所提模型能够从配对与非配对训练数据中有效提升水下图像质量。更重要的是，增强后的图像在水下目标检测、人体姿态估计及显著性预测等标准模型性能上均取得显著提升。这些结果验证了该模型适用于自主航行水下机器人视觉引导系统中的实时预处理环节。模型及相关训练流程已公开发布。https://github.com/xahidbuffon/funie-gan。

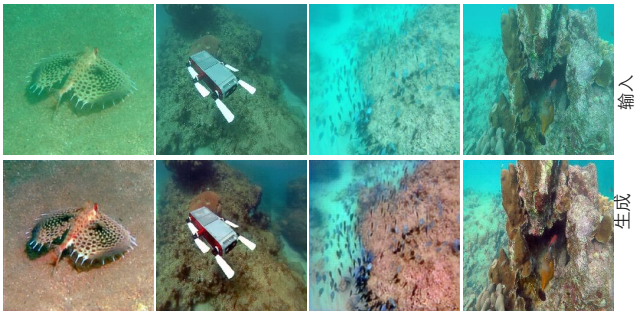

(a) 水下图像的感知增强

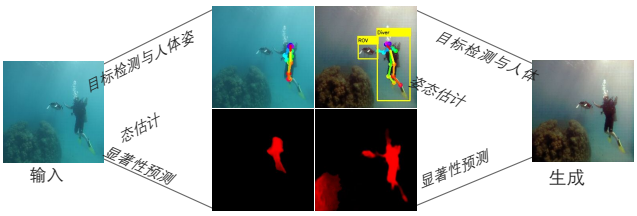

(b) 在水下目标检测[23]、人体姿态估计[9]及显著性预测[40]方面性能得到提升。

图1：采用我们提出的模型进行水下图像增强效果演示及其实际可行性验证。

1. 引言

视觉引导式自主水下航行器（AUV）和遥控潜水器（ROV）在多个重要领域得到广泛应用，例如海洋物种迁徙监测与珊瑚礁研究[39]、海底电缆及沉船残骸检测[5]、水下场景分析、海底测绘、人机协作[24]等。这些水下机器人面临的主要操作挑战在于：尽管配备了高端摄像头，但视觉感知常受能见度差、光线折射、吸收与散射等因素严重影响[31, 45, 24]。这些光学伪影会导致图像产生非线性畸变，严重影响基于视觉的任务执行效果，包括目标追踪、检测分类、图像分割及视觉伺服控制等。通过实时恢复畸变图像的感知特征与统计特性[15, 45]，快速精准的图像增强技术可有效缓解这些问题。

由于水下光传播特性与大气层存在显著差异，会产生一系列独特的非线性图像畸变现象，这些畸变受多种因素共同影响。例如，水下图像常呈现明显的绿色或蓝色调[15]，这是因为红光波长在深水中会被吸收（随着光程延长）。水体具有波长依赖性衰减[2]、散射等光学特性，会导致不规则的非线性畸变[18, 45]，从而形成对比度低、常出现模糊及色彩失真的图像。其中部分特性可通过基于物理原理的解决方案进行建模与精准估算，尤其适用于去雾处理和色彩校正[7, 4]。如何

在许多机器人应用中，诸如场景深度和光学水质指标等信息并非始终可用。此外，这些模型通常对实时部署而言计算需求过高。

一个实用的替代方案是通过基于学习的方法来近似基础解，这类方法近年来已展现出显著成效。基于深度卷积神经网络（CNN）和生成对抗网络（GAN）的多种模型，在从大量配对或非配对数据中学习提升感知图像质量方面表现卓越[21, 10, 25, 47]。特别是在水下成像领域，基于GAN的模型[15, 43]与基于CNN的残差网络模型[29]在自动色彩增强、去雾处理及对比度调节方面取得了突破性进展。然而，由于水下图像感知增强属于比陆地影像更具挑战性的不适定问题，现有模型仍有显著提升空间。此外，由于获取大规模水下数据存在高昂成本与技术难度，多数基于学习的模型仅采用小规模且多为人工合成的图像样本，难以捕捉自然环境中的广泛差异性特征。此外，设计稳健且高效的图像增强模型，并探究其在提升实时水下视觉感知能力方面的适用性，尚未在文献中得到深入探讨。

为应对这些挑战，我们通过设计快速水下图像增强模型并分析其实时应用可行性展开研究。我们将问题建模为图像间转换问题，假设存在从畸变输入图像到增强输出图像的非线性映射关系。随后，基于条件生成对抗网络（Conditional GAN）模型，在名为 EUVP（水下视觉感知增强）的大规模数据集上通过对抗训练学习该映射关系。从设计思路、实现方法及实验验证三个维度，本文主要取得以下研究成果：

(a) 我们提出了一种基于全卷积条件生成对抗网络（GAN）的实时水下图像增强模型，命名为FUnIE-GAN。通过构建多模态目标函数对模型进行训练，该函数基于图像的整体内容、色彩特征、局部纹理及风格信息来评估其感知质量。

(b) 此外，我们还提供了 EUVP 数据集，该数据集包含20K张水下图像（包含低质量与高质量图像）的配对与非配对集合，可用于*单向*与*双向*对抗训练[10, 47]。该数据集可在 http://irvlab.cs.umn.edu/resources/euvp-dataset 获取。

(c) 此外，我们还与最先进模型进行了定性和定量性能评估。实验结果表明，FUnIE-GAN能够通过配对训练和非配对训练有效提升图像感知质量。更重要的是，经过增强处理的图像在物体检测、人体姿态估计、显著性预测等多项水下视觉感知任务中均展现出显著性能提升，部分典型案例展示详见图1。

除展示FUnIE-GAN的概念模型外，我们还深入分析了其高效实现过程中关键的设计决策与实际应用要点。通过开展用户调研和系统可行性分析，我们验证了该模型在提升视觉引导水下机器人实时感知性能方面的有效性。

2. 相关工作

2.1. 自动图像增强

自动图像增强是计算机视觉、机器人技术及信号处理领域中经过深入研究的课题。传统方法通过人工设计滤波器来实现局部色彩恒定性，并提升对比度与亮度表现[37]。此外，针对场景的先验知识或统计假设（*例如*雾霾线、暗通道先验[4]等）常被用于全局增强处理，如图像去模糊、去雾[19]等。过去十年间，随着深度学习技术的兴起和大规模数据集的可用性，单图像增强技术取得了显著进展。当前基于深度卷积神经网络的模型在图像着色[44]、色彩/对比度调节[11]、去雾[8]等领域展现出顶尖性能。这些模型通过配对训练数据学习非线性滤波器序列，相较于人工设计滤波器展现出更优的性能表现。

此外，基于生成对抗网络（GAN）的模型[16]在风格迁移和图像间转换问题上取得了显著成效[25]。这类模型采用双玩家最小最大博弈机制：生成器通过生成看似来自*真实*分布的伪图像来欺骗判别器，而判别器则通过提升对伪图像的过滤能力进行反制。最终在均衡状态下，生成器能够准确建模底层分布。尽管对抗训练可能引发系统不稳定，学界已提出多种技巧和损失函数选择方案来缓解这一问题。例如，瓦瑟斯坦GAN[3]通过采用地球移动距离度量数据分布与模型分布间的差异来提升训练稳定性；基于能量函数的GAN[46]通过将判别器建模为能量函数来增强训练稳定性；而最小二乘GAN[33]则通过采用最小二乘损失函数解决梯度消失问题。

另一方面，条件GAN[34]允许约束生成器生成遵循特定模式或属于特定类别的样本，这对于学习任意输入域（*例如*扭曲图像）与期望输出域（*例如*增强图像）之间的像素到像素（Pix2Pix）映射[25]尤为有用。

上述模型的主要局限性在于需要配对训练数据，这在许多实际应用中可能无法获得或难以获取。双向生成对抗网络（*例如*CycleGAN[47]、DualGAN[42]等）通过引入‘循环一致性损失’解决了这一问题，该机制允许从非配对数据中学习两个域之间的相互映射关系。此类模型在感知图像增强的非配对学习领域也已得到有效应用[10]。此外，Ignatov *等人* 的研究进一步拓展了该领域应用。[21] 研究表明，为保留基于高级特征的内容而引入额外的损失项，可提升基于生成对抗网络（GANs）的图像增强质量。

2.2. 改善水下视觉感知能力

传统的基于物理的方法利用大气去雾模型来估计场景中的*透射光*和*环境光*，以恢复真实的像素强度[12, 7]。另一类方法设计了一系列双边和三边滤波器以减少噪声并提高全局对比度[31, 45]。在最近的研究中，Akkaynaket *等人* 。[2] 提出了一种修订后的成像模型，该模型考虑了水下光传播特有的畸变效应；这有助于实现更精确的颜色重建，并总体上更好地逼近不适定水下图像增强问题。然而，这些方法仍需以场景深度（或多幅图像）及光学水体测量数据作为先验条件。

另一方面，近期基于深度对抗学习[15, 43, 28]和残差学习[29]的多种单图像增强模型已取得令人鼓舞的成果。然而这些模型通常仅使用人工合成的畸变图像进行配对训练，这往往限制了其泛化性能。目前学术界尚未探索大规模非配对训练在自然畸变水下图像上的应用范围。此外，现有大多数模型仍无法确保在单板机器人平台上实现快速推理。
这限制了其在改善实时视觉感知方面的应用价值。本文试图针对这些方面进行探讨。

3. 所提模型与数据集

3.1. FUnIE-GAN架构

给定源域X（包含失真图像）和目标域Y（包含增强图像），我们的目标是学习映射$G{:}X\rightarrow Y$以实现自动图像增强。我们采用基于条件GAN的模型，其中生成器通过与对抗判别器进行迭代最小-最大博弈来学习该映射。如图2所示，我们遵循U-Net[38]的设计原则构建生成器网络。该网络为编码器-解码器结构（e_1-e_5,d_1-d_5），镜像层之间存在连接*即*（e_1, d_5),(e_2, d_4), (e_3, d_2）及（e_4, d_4）。具体而言，各编码器的输出被拼接至对应的镜像解码器。生成器网络中*跳跃连接*的设计已被证明对图像间转换及图像质量增强问题具有显著效果[25, 10, 15]。但在FUnIE-GAN中，我们采用参数更少的简化模型以实现快速推理。网络的输入被设置为256 × 256 × 3，编码器（e_1-e_5）仅学习256个尺寸为8 × 8的特征图。解码器（d_1-d_5）利用这些特征图及跳跃连接层的输入，学习生成256 × 256 × 3（增强型）图像作为输出。该网络采用全卷积结构，未使用全连接层。此外，每层均应用4 × 4滤波器的二维卷积运算，随后接Leaky-ReLU非线性激活函数[32]和批量归一化（BN）[22]。各层特征图尺寸及其他模型参数标注于图2a中。

对于判别器，我们采用马尔可夫式PatchGAN[25]架构，该架构假设像素在补丁尺寸之外具有独立性，*即*仅基于补丁层级信息进行判别。这一假设对于有效捕捉局部纹理和风格等高频特征至关重要[42]。此外，相较于图像层级的全局判别，该配置在计算效率上更具优势，因其所需参数更少。如图2b所示，四个卷积层用于将256 × 256 × 6的输入（真实图像与生成图像）转换为16 × 16 × 1的输出，该输出代表判别器的平均*有效性*响应。每层采用步长为2的3 × 3卷积滤波器，随后非线性层与贝叶斯网络的处理方式与生成器保持一致。

3.2. 目标函数构建

基于标准条件GAN的模型学习映射$G{:}\{X,\ Z\}\rightarrow Y$，其中$X$($Y$)表示源（期望）域，$Z$表示随机噪声。条件对抗损失函数[34]表示为：

$$\mathcal{L}_{cGAN}(G,\ D) = \mathbb{E}_{X,Y}[\log D(Y)] + \mathbb{E}_{X,Y}[\log(1 - D(X,\ G(X,\ Z)))] \tag{1}$$

在此，生成器G试图最小化$\mathcal{L}_{cGAN}$，而判别器D则试图最大化它。在FUnIE-GAN中，我们在目标函数中关联了三个额外方面，*即*全局相似性、图像内容以及局部纹理和风格信息，以量化感知图像质量。

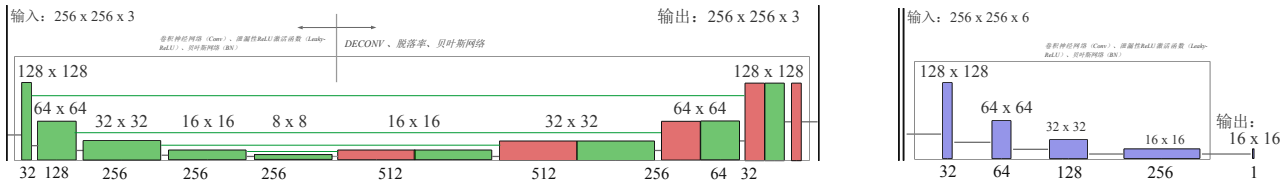

(a) 生成器：采用五组镜像跳跃连接的编码器-解码器对（灵感来源于U-Net的成功[38]；但该模型结构更为简化）。

(b) 判别器：一个具有四层结构、补丁尺寸为16 × 16的马尔可夫式PatchGAN[25]。

图2：所提模型FUnIE-GAN的网络架构。

- **全局相似性**：现有方法表明，在目标函数中添加L_1 (L_2）损失项可使G学会从全局相似空间中进行采样，且这种采样在L_1 (L_2）意义上具有意义[25, 43]。由于L_1损失不易引入模糊效应，我们在目标函数中添加了以下损失项：

$$\mathcal{L}_1(G) = \mathbb{E}_{X,Y,Z}\left[||Y - G(X,Z)||_1\right] \quad (2)$$

- **图像内容**：我们在目标函数中加入*内容损失*项，以促使G生成增强图像，使其具有与目标图像（*即*真实图像）相似的内容（*即*特征表示）。受[26, 21]启发，我们将图像内容函数 Φ（·）定义为预训练 VGG -19网络中block5 conv2层提取的高层次特征。随后，我们按如下方式构建内容损失函数：

$$\mathcal{L}_{con}(G) = \mathbb{E}_{X,Y,Z}\left[||\Phi(Y) - \Phi(G(X,Z))||_2\right] \quad (3)$$

- **局部纹理与风格**：如前所述，马尔可夫PatchGANs能有效捕捉与局部纹理和风格相关的高频信息[25]。因此，我们采用D以对抗性方式强制实现局部纹理与风格的一致性。

3.2.1 配对训练

在配对训练中，我们构建了一个目标函数来引导G学习提升感知图像质量，使得生成图像在整体外观和高层次特征表征方面与对应真实图像高度接近。另一方面，D会剔除纹理和风格存在局部不一致的生成图像。具体而言，我们为配对训练采用以下目标函数：

$$G^* = \arg\min_G \max_D \mathcal{L}_{cGAN}(G,D) + \lambda_1 \mathcal{L}_1(G) + \lambda_c \mathcal{L}_{con}(G)$$

此处，λ_1= 0.7 和λ_c= 0.3 是我们通过经验调整为超参数的缩放因子。

3.2.2 非配对训练

对于非配对训练，由于无法获得成对的真实数据，我们不会强制执行全局相似性和内容损失约束。相反，目标是通过保持循环一致性，同时学习前向映射G_F：$\{X, Z\} \rightarrow Y$和重构G_R：$\{Y, Z\} \rightarrow X$。正如Zhu等人所建议的那样。[47]我们将循环一致性损失定义如下：

$$\mathcal{L}_{cyc}(G_F, G_R) = \mathbb{E}_{X,Y,Z}\left[||X - G_R(G_F(X,Z))||_1\right] + \mathbb{E}_{X,Y,Z}\left[||Y - G_F(G_R(Y,Z))||_1\right] \quad (4)$$

因此，我们对非配对训练的目标是：

$$G^*_F, G^*_R = \arg\min_{G_F, G_R} \max_{D_Y, D_X} \mathcal{L}_{cGAN}(G_F, D_Y) + \mathcal{L}_{cGAN}(G_R, D_X) + \lambda_{cyc}\mathcal{L}_{cyc}(G_F, G_R)$$

此处，D_Y (D_X) 是与生成器G_F (G_R) 相关的判别器，而缩放因子λ_{cyc}= 0.1 是一个经验调参的超参数。我们未强制添加额外的全局相似性损失项，因为$\mathcal{L}_{cyc}$在L_1空间中为每个域计算了类似的重构损失。

3.3. EUVP 数据集

EUVP 数据集包含大量成对及非成对的水下图像，其感知质量参差不齐。我们使用了七种不同相机来采集数据集图像，包括多台GoPro相机[17]、Aqua AUV的uEye相机[14]、低光USB相机[6]以及Trident ROV的高清相机[35]。这些数据采集自不同地点的海洋探索及人机协作实验，涵盖多种能见度条件。此外，数据集中还包含了从若干公开YouTube ™视频中提取的图像。图像经过精心筛选，以适应数据中广泛存在的自然变异性（*例如*场景类型、水体种类、光照条件等）。

未配对数据已准备就绪，*即*通过六人目视检查将高质量与低质量图像进行分离。

(a) 配对实例：真实图像及其对应畸变对分别显示于上行和下行。

(b) 未配对实例：高质量与低质量图像分别显示于上排与下排（无特定顺序）。

图3：展示了 EUVP 数据集中部分样本图像。

人类受试者。他们检查了若干图像属性（*例如*颜色、对比度和锐度），并评估场景是否具有视觉可解释性，*即*前景/物体是否可识别。因此，非配对训练数据支持对人类水下图像质量感知偏好的建模。另一方面，配对数据的准备遵循[15]中提出的流程。具体而言，基于CycleGAN[47]的模型在非配对数据上进行训练，以学习优质与劣质图像之间的领域转换。随后，通过学习模型对优质图像进行畸变处理以生成对应配对样本；同时我们还从ImageNet数据集[13]和Flickr ™中扩充了一组水下图像。

EUVP 数据集中包含超过12K个配对实例和8K个非配对实例；部分样本展示于图3。需要特别说明的是，我们的研究重点在于促进感知*图像增强*以提升机器人场景理解能力，而非针对*图像恢复*建模水下光学退化过程——后者需要考虑场景深度与水体特性参数。

4. 实验结果

我们采用TensorFlow库[1]实现FUnIE-GAN模型。该模型分别在11K对样本和7.5K非配对样本上进行独立训练，其余样本分别用于验证集和测试集。训练过程中使用四块 NVIDIA ™ GeForce GTX 1080显卡，两个模型均以8的批量大小进行6万至7万次迭代训练。本文通过定性分析、标准量化指标及用户调研结果，对实验评估结果进行系统呈现。

4.1. 定性评估

我们首先对FUnIE-GAN生成图像相较于各自真实图像在色彩增强和锐度提升方面进行定性分析。如图4a所示，增强图像中真实色彩与锐度基本得以恢复。此外，图4b显示水下图像中的绿色调得到修正，整体对比度也得到提升。这些是有效水下图像增强器的主要特征。我们进一步展示了FUnIE-GAN中各损失项对增强学习的贡献：全局相似性损失（$\mathcal{L}_1$）与图像内容损失（$\mathcal{L}_{con}$）。观察发现$\mathcal{L}_1$项有助于生成更锐利的图像，而$\mathcal{L}_{con}$项则能提供更精细的纹理细节（见图4c）。此外，相较于最后特征提取层（block5 conv 4），VGG -19模型中采用block5 conv2层时，$\mathcal{L}_{con}$的数值稳定性略优。

接下来，我们对FUnIE-GAN与若干前沿模型在感知图像增强方面的定性比较进行分析。我们考虑了五种基于学习的模型：
(i) 采用梯度惩罚的水下GAN（UGAN -P[15]）、（ii）Pix2Pix[25]、（iii）最小二乘GAN（LS-GAN[33]）、（iv）生成器中带有残差块的GAN（ResGAN[27]）以及(v)生成器中带有残差块的Wasserstein GAN（Res-WGAN）。这些模型在生成器网络中采用8对编码器-解码器（或16个残差块），判别器中包含5个卷积层，并使用与FUnIE-GAN相同的配置在配对 EUVP 数据集上进行训练。此外，我们以CycleGAN[47]作为基线模型，用于比较FUnIE-GAN在非配对训练下的性能（*即* FUnIE-GAN-UP）。对比研究中还纳入了两种基于物理原理的模型：多波段融合增强（Mbad-EN[12]）和雾线感知色彩还原（Uw-HL[4]）。定性评估采用包含1K张图像（分辨率× 256）的通用测试集，其中包含72张已知水体类型的图像[4]。部分样本对比结果如图5所示。

如图5所示，Res-GAN、Res- WGAN 和Mbad-EN常出现过饱和现象，而 LSGAN 算法普遍难以修正图像中的绿色调。 UGAN -P、Pix2Pix和Uw-HL表现较为理想，其增强效果与FUnIEGAN相当；但 UGAN -P常导致场景中亮色物体过度饱和，Pix2Pix在某些情况下也难以提升整体亮度。另一方面，我们发现通过无对齐学习实现色彩一致性与色调校正具有相对更高的挑战性。

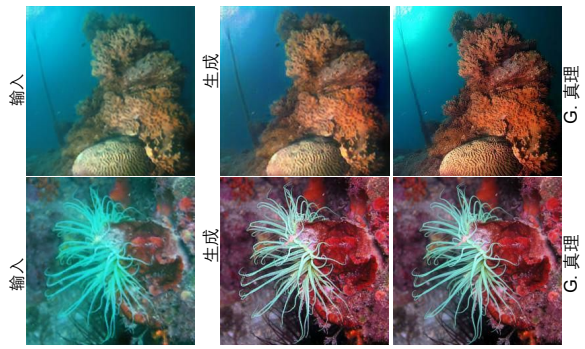

(a) 增强后的图像可恢复真实色彩与锐度。

(b) 绿色调被校正且全局对比度得到增强。

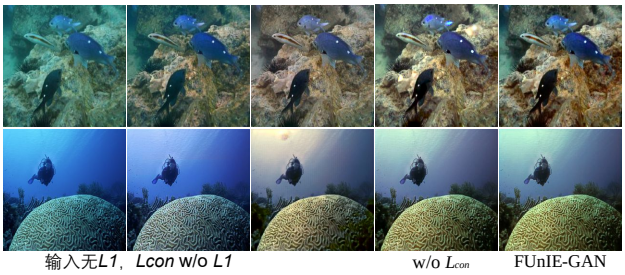

(c) 消融实验：在FUnIE-GAN中不使用（无）$\mathcal{L}_1$和$\mathcal{L}_{con}$、无$\mathcal{L}_1$以及无$\mathcal{L}_{con}$损失项时的学习增强效果。

图4：图像属性改善效果的演示
FUnIE-GAN在色彩、锐度与对比度方面的表现。

这主要是由于损失函数中缺乏参考颜色或纹理信息所致。尽管如此，FUnIEGAN-UP在整体性能上仍优于CycleGAN。总体而言，FUnIEGAN无需使用场景深度或先验水体信息（与基于物理模型不同），且网络架构较现有学习型模型更为简洁，其性能表现与物理模型相当甚至更优。

4.2. 定量评估

我们采用两种标准指标[21, 10, 20]——峰值信噪比（PSNR）和结构相似性（SSIM），用于定量比较FUnIE-GAN增强图像与其对应的真实图像。PSNR通过计算生成图像$\mathbf{x}$与真实图像$\mathbf{y}$之间的均方误差（MSE），来评估重建质量，具体计算公式如下：

$$PSNR(\mathbf{x}, \mathbf{y}) = 10\log_{10}[255^2/MSE(\mathbf{x}, \mathbf{y})] \quad (5)$$

另一方面，SSIM[41]基于亮度、对比度和结构三个属性对图像块进行比较。其定义如下：

$$SSIM(\mathbf{x}, \mathbf{y}) = \left(\frac{2\mu_{\mathbf{x}}\mu_{\mathbf{y}} + c_1}{\mu_{\mathbf{x}}^2 + \mu_{\mathbf{y}}^2 + c_1}\right)\left(\frac{2\sigma_{\mathbf{xy}} + c_2}{\sigma_{\mathbf{x}}^2 + \sigma_{\mathbf{y}}^2 + c_2}\right) \quad (6)$$

在等式6中，$\mu_{\mathbf{x}}$ ($\mu_{\mathbf{y}}$) 表示均值，而$\sigma_{\mathbf{x}}^2$($\sigma_{\mathbf{y}}^2$) 是$\mathbf{x}$($\mathbf{y}$) 的方差；而$\sigma_{\mathbf{xy}}$表示$\mathbf{x}$与$\mathbf{y}$之间的互相关。此外，$c_1 = (255 \times 0.01)^2$和$c_2 = (255 \times 0.03)^2$是确保数值稳定性的常数。

在表1中，我们展示了FUnIE-GAN在1000张测试图像上的平均 PSNR 和 SSIM 值，并将结果与定性评估中使用的相同模型进行对比。结果表明，FUnIE-GAN在 PSNR 和 SSIM 指标上均表现最佳。我们对水下图像质量度量（UIQM）[36, 30]进行了类似分析，该指标用于量化水下图像的色彩饱和度、锐度和对比度。表2显示，尽管FUnIE-GAN-UP在配对数据集上的UIQM 值优于CycleGAN，但其表现仍相对欠佳。值得注意的是，基于配对数据训练的模型（尤其是FUnIE-GAN、UGANP 和Pix2Pix）取得了更优结果。我们推测这可能与以下因素有关：

表1：EUVP 数据集中1K对测试图像的平均 PSNR 与 SSIM 值定量比较。

模型	$PSNR(G(\mathbf{x}), \mathbf{y})$ 输入：17.27 ± 2.88	$SSIM(G(\mathbf{x}), \mathbf{y})$ 输入：0.62 ± 0.075
Uw-HL	18.85 ± 1.76	0.7722 ± 0.066
Mband-EN	12.11 ± 2.55	0.4565 ± 0.097
Res-WGAN	16.46 ± 1.80	0.5762 ± 0.014
Res-GAN	14.75 ± 2.22	0.4685 ± 0.122
LS-GAN	17.83 ± 2.88	0.6725 ± 0.062
Pix2Pix	20.27 ± 2.66	0.7081 ± 0.069
UGAN-P	19.59 ± 2.54	0.6685 ± 0.075
循环GAN	17.14 ± 2.65	0.6400 ± 0.080
FUnIE-GAN-UP	21.36 ± 2.17	0.8164 ± 0.046
FUnIE-GAN	21.92 ± 1.07	0.8876 ± 0.068

表2：EUVP 数据集中1K对齐测试图像与2K非对齐测试图像的平均 UIQM 值定量比较。

模型	配对数据 输入：2.20 ± 0.69 G. 真实值：2.91 ± 0.65	非配对数据 输入：2.29 ± 0.62 G. 真相：不适用
Uw-HL	2.62 ± 0.35	2.75 ± 0.32
Mband-EN	2.28 ± 0.87	2.34 ± 0.45
Res-WGAN	2.55 ± 0.64	2.46 ± 0.67
Res-GAN	2.62 ± 0.89	2.28 ± 0.34
LS-GAN	2.37 ± 0.78	2.59 ± 0.52
Pix2Pix	2.65 ± 0.55	2.76 ± 0.39
UGAN-P	2.72 ± 0.75	2.77 ± 0.34
循环GAN	2.44 ± 0.71	2.62 ± 0.67
FUnIE-GAN-UP	2.56 ± 0.63	2.81 ± 0.65
FUnIE-GAN	2.78 ± 0.43	2.98 ± 0.51

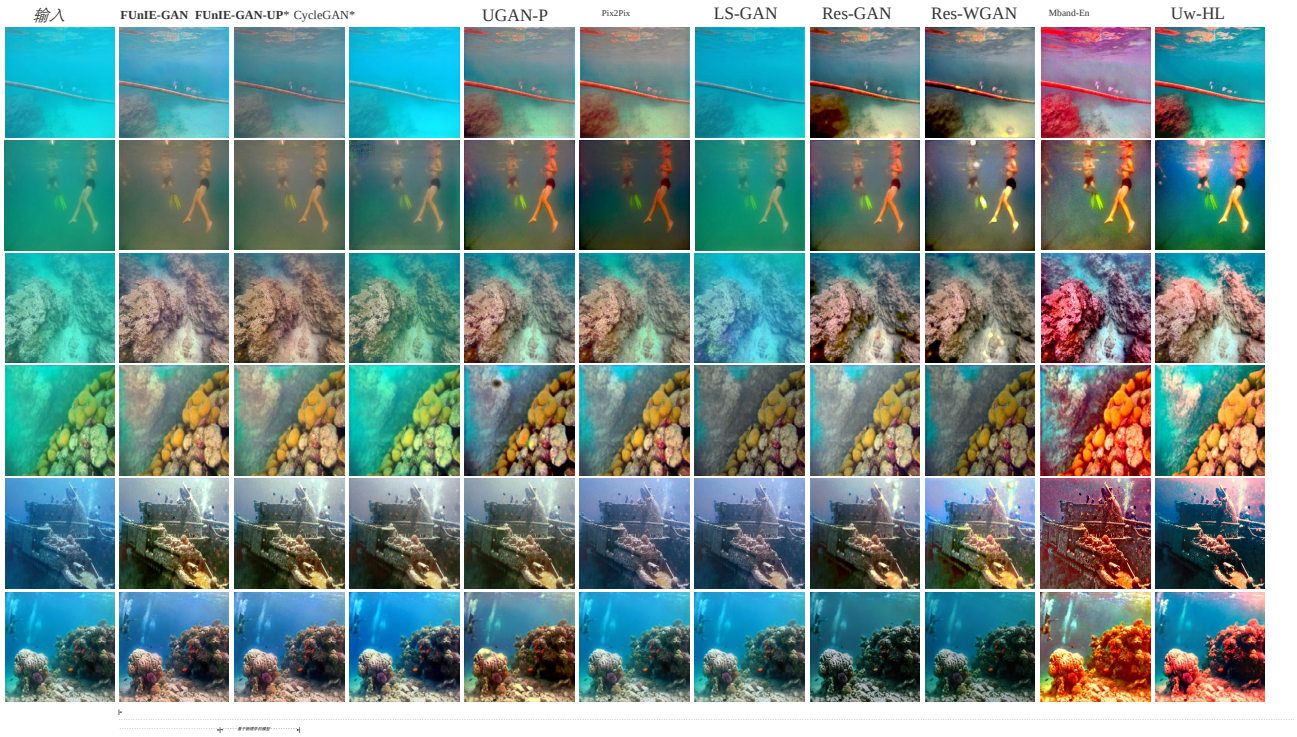

图5：FUnIE-GAN与FUnIE-GAN-UP相对于基于学习方法的定性性能对比：CycleGAN[47]、 UGAN -P[15]、Pix2Pix[25]、LS-GAN[33]、Res-GAN[27]及Res- WGAN[3]；上标星号（*）表示未配对训练。对比中还包含两种基于物理模型：Mband-EN[12]与Uw-HL[4]。（最佳查看效果为400%缩放）

FUnIE-GAN和Pix2Pix中的全局相似性损失项，或UGAN -P中的梯度惩罚项共同促进了这一提升效果，因为它们都在对抗目标函数中加入了L_1项。我们对FUnIE-GAN的消融实验（见图4c）表明，$\mathcal{L}_1$损失项使UIQM 提升了4.58%，而$\mathcal{L}_{con}$损失项贡献了1.07%。此外，若同时移除$\mathcal{L}_1$和$\mathcal{L}_{con}$损失项，平均 UIQM 值将下降17.6%； PSNR 和 SSIM 也呈现出相似的统计结果。

4.3. 用户研究

我们还开展了一项用户研究，以将人类偏好纳入定性性能分析中。受试者被展示不同组别的9张图像（每个基于学习的模型对应一组），并被要求对质量最佳的前三张图像进行排序。共有78名受试者参与了该研究，总计共记录到312份反馈数据。表3对比了前4个类别在第一、第二和第三位准确率的平均值。原始图像的平均第三位准确率为6.67，这表明用户明显更青睐经过增强处理的图像。此外，实验结果还显示用户对FUnIE-GAN、 UGAN -P和Pix2Pix增强图像的偏好度显著高于其他模型，这些数据与我们的定性分析和定量研究结果高度吻合。

表3：基于78名受试者提供的312份应答数据，前四种模型的秩-*n*准确率（*n*= 1,2,3）。

模型	秩-1（%）	2级（%）	3级（%）
FUnIE-GAN	24.50	68.50	88.60
FUnIE-GAN-UP	18.67	48.25	76.18
UGAN-P	21.25	65.75	80.50
Pix2Pix	11.88	45.15	72.45

4.4. 视觉感知的改善

如图6a所示，我们通过进一步实验对FUnIEGAN增强图像在多种测试场景下的水下视觉感知效果进行定量分析。我们评估了标准深度视觉模型在水下目标检测[23]、二维人体姿态估计[9]以及基于视觉注意力的显著性预测[40]方面的性能表现。尽管具体测试集的图像质量会影响结果差异，但平均而言我们观察到分别提升了11-14%、22-28%和26-28%的性能指标。同时我们在相同测试集上评估了其他前沿模型：如图6b所示，经 UGAN -P、Res-GAN、Res- WGAN 、Uw-HL和Pix2Pix增强的图像同样实现了显著的

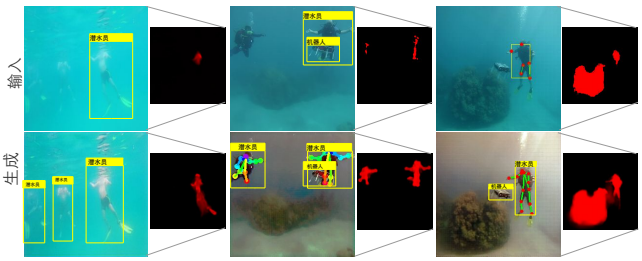

(a) 若干快照显示FUnIEGAN生成图像的质量提升；详细演示可参见：https://youtu.be/1ewcXQ-jgB4。

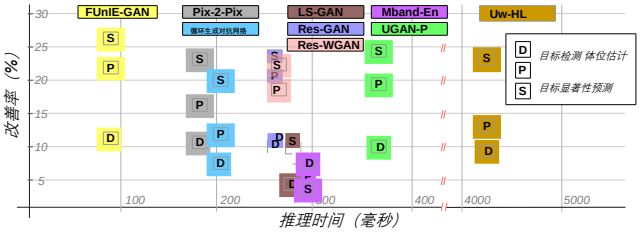

(b) 与最先进模型相比，FUnIE-GAN在改进与推理时间上的对比显示：在常见平台（Intel ™ Core-i5 3.6GHz CPU）上可实现超过10帧/秒的速度提升；需注意所有模型的运行时间均基于256 × 256图像块进行评估。

图6：增强图像在物体检测、显著性预测及人体姿态估计方面的性能提升。

虽然性能有所提升，但这些模型的推理速率显著低于FUnIE-GAN，其中大多数模型并不适用于机器人平台的实时部署场景。

FUnIE-GAN的内存需求为17MB，在单板计算机（NVIDIA ™ Jetson TX2）上运行速度为25.4帧/秒，在显卡（NVIDIA ™ GTX 1080）上为148.5帧/秒，在机器人CPU（Intel ™ Core-i3 6100U）上为7.9帧/秒。这些计算性能使其非常适合用作视觉引导水下机器人在实时应用中的图像处理流水线。

4.5. 局限性与失败案例

我们观察到FUnIEGAN存在几个具有挑战性的案例，如图7所示的几个示例。首先，FUnIE-GAN在增强严重退化且缺乏纹理的图像时效果欠佳。此类情况下生成的图像常因噪声放大而出现过饱和现象。虽然色调校正通常较为准确，但色彩还原与纹理恢复效果仍不尽如人意。其次，FUnIEGAN-UP易出现训练不稳定现象。研究表明，判别器往往过早达到过优状态，导致*梯度衰减效应*阻碍生成器的学习进程。如图7

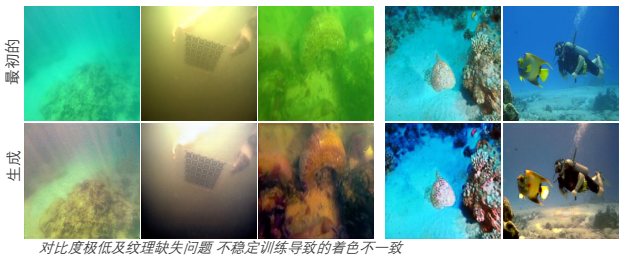

（右）所示，生成图像7：极低对比度且无纹理的图像对FUnIE-GAN普遍具有挑战性，而FUnIEGAN-UP则常因训练不稳定导致着色效果不一致。

此类情况下生成的图像缺乏色彩一致性及精确的纹理细节。这是生成对抗网络（GAN）非配对训练中较为常见的问题[10, 21, 26]，需要进行精细的超参数调优。

FUnIE-GAN在鲁棒性与效率之间进行了权衡，这在一定程度上限制了其性能表现。对于非实时应用场景，可采用更强大的深度模型（*即*参数量更大的密集架构）；此外，输入/输出层可通过添加瓶颈层进行优化，从而在分辨率超过256 × 256时提升学习效果。但需注意的是，FUnIE-GAN专为感知图像质量增强设计，无法保证真实像素强度的还原。若具备场景深度和光学水体特性数据，可将水下光传播规律与图像形成特征[2, 4, 7]纳入优化模型，以实现更精准的图像复原效果。

5. 结论

我们提出了一种简单高效、基于条件生成对抗网络（conditional GAN）的水下图像增强模型。该模型通过综合评估图像的整体色彩、内容特征、局部纹理及风格信息，构建了感知损失函数。我们还提供了包含配对与非配对水下图像的大规模数据集用于监督学习训练。通过系统性的定性与定量评估及用户调研表明，该模型不仅性能媲美甚至超越现有主流模型，同时显著缩短了推理时间。实验结果进一步证实其在水下目标检测、显著性预测及人体姿态估计等任务中的提升效果。未来计划拓展该模型在水下人机协作系统、海洋垃圾识别等场景的应用可行性，并致力于提升非配对训练过程中的色彩一致性与稳定性。

参考文献

[1] M. Abadi, P. Barham, J. Chen, Z. Chen, A. Davis, J. Dean, 等人.TensorFlow:一个大规模机器学习系统.收录于*USENIX操作系统设计与实现研讨会(OSDI)*,第265–283页,2016年.5

[2] D. Akkaynak 和 T. Treibitz. 修订版水下图像形成模型. 在*IEEE 计算机视觉与模式识别会议 (CVPR)*上，第 6723–6732 页，2018 年。1，3，8

[3] M. Arjovsky、S. Chintala 和 L. Bottou. Wasserstein 生成对抗网络. 在*国际机器学习会议（ICML）*上，第 214–223 页，2017 年。2、5、7

[4] D. Berman、D. Levy、S. Avidan 和 T. Treibitz。基于雾霾线与新定量数据集的水下单图像彩色恢复。*arXiv预印本 arXiv:1811.01343*，2018。1、2、5、7、8

[5] B. Bingham, B. Foley, H. Singh, R. Camilli, K. Delaporta, R. Eustice, 等. 深水考古学中的机器人工具:使用自主水下航行器勘测古代沉船.*《野外机器人学杂志(JFR)》*,27(6): 702–717,2010.1

[6] BlueRobotics. 低光高清USB摄像头.https://www.bluerobotics.com/，2016. 访问日期: 2019年3月15日.4

[7] M. Bryson、M. Johnson-Roberson、O. Pizarro 和 S. B. Williams。自主水下航行器影像的真彩色校正。*《野外机器人学杂志（JFR）*，33(6):853–874,2016。1、3、8

[8] B. Cai、X. Xu、K. Jia、C. Qing 和 D. Tao。DehazeNet：一种用于单图像雾霾去除的端到端系统。*IEEE图像处理汇刊*，25(11):5187–5198,2016。2

[9] Z. Cao、T. Simon、S.-E. Wei 和 Y. Sheikh。基于部件亲和场的实时多人二维姿态估计。收录于*IEEE计算机视觉与模式识别会议（CVPR）*，第7291–7299页，2017年。1，7

[10] Y.-S. Chen、Y.-C. Wang、M.-H. Kao 和 Y.-Y. Chuang。深度照片增强器：基于GAN的未对齐学习用于照片图像增强。收录于*IEEE计算机视觉与模式识别会议（CVPR）*，第6306–6314页。IEEE，2018。2、3、6、8

[11] 成泽、杨琦和盛斌. 深度着色. 在*IEEE国际计算机视觉会议(ICCV)上*，第415–423页，2015年。2

[12] Y. Cho、J. Jeong 和 A. Kim. 基于模型辅助的多波段融合用于单图像增强及在机器人视觉中的应用。*IEEE Robotics and Automation Letters (RA L)*，3(4):2822–2829,2018。3、5、7

[13] J. Deng、W. Dong、R. Socher、L.-J. Li、K. Li 和 L. FeiFei. ImageNet：一个大规模分层图像数据库。收录于*计算机视觉与模式识别会议（CVPR）*，第248–255页。IEEE，2009。5

[14] G. Dudek, P. Giguere, C. Prahacs, S. Saunderson, J. Sattar, L.-A. Torres-Mendez, Jenkin, 等. Aqua:一种两栖自主机器人.*计算机*,40(1):46–53,2007.4

[15] C. Fabbri、M. J. Islam 和 J. Sattar。利用生成对抗网络增强水下成像。收录于*IEEE国际机器人与自动化会议（ICRA）*，第7159–7165页。IEEE，2018。1、2、3、5、7

[16] I. Goodfellow、J. Pouget-Abadie、M. Mirza、B. Xu、D. Warde-Farley、S. Ozair、A. Courville 和 Y. Bengio. 生成对抗网络. 收录于*神经信息处理系统进展（NIPS）*，第2672–2680页，2014年。2

[17] GoPro。GoPro Hero 5。https://gopro.com/，2016年。访问日期：2019年3月15日。4

[18] Y. Guo、H. Li 和 P. Zhuang。基于多尺度密集生成对抗网络的水下图像增强。*IEEE海洋工程学报*，2019。1

[19] K. He、J. Sun 和 X. Tang. 基于暗通道先验的单图像雾霾去除方法。*IEEE模式分析汇刊*
《解剖学与机器智能》，33(12):2341–2353,2010。2

[20] A. Hore与D. Ziou. 图像质量指标： PSNR 与 SSIM .*国际模式识别会议*，第2366–2369页。IEEE，2010。6

[21] A. Ignatov、N. Kobyshev、R. Timofte、K. Vanhoey 及 L. Van Gool。基于深度卷积网络的移动设备 DSLR 级照片处理。发表于*IEEE国际计算机视觉会议(ICCV)*，第3277–3285页，2017年。2、3、4、6、8

[22] S. Ioffe 和 C. Szegedy. 批量归一化：通过减少内部协变量偏移加速深度网络训练。*CoRR，abs/1502.03167*，2015。3

[23] M. J. Islam、M. Fulton 和 J. Sattar. 通用型跟随式算法研究：深度视觉检测中鲁棒性与效率的平衡。*IEEE机器人与自动化快报（RA-L）*，4(1):113–120,2018。1，7

[24] M. J. Islam、M. Ho与J. Sattar. 水下人机协作中人体运动与手势的理解.*现场机器人学杂志(JFR)*，第1–23页，2018年。1

[25] P. Isola、J.-Y. Zhu、T. Zhou 和 A. A. Efros。基于条件对抗网络的图像间翻译。收录于*IEEE计算机视觉与模式识别会议（CVPR）*，第1125–1134页，2017年。2、3、4、5、7

[26] J. Johnson、A. Alahi 和 L. Fei-Fei. 实时风格迁移与超分辨率中的感知损失。见*欧洲*
计算机视觉会议（ECCV），第694–711页。Springer出版社，2016年。4，8

[27] J. Li、X. Liang、Y. Wei、T. Xu、J. Feng 和 S. Yan。小目标检测中的感知生成对抗网络。收录于*IEEE计算机视觉与模式识别会议（CVPR）*，第1222–1230页，2017年。5，7

[28] J. Li、K. A. Skinner、R. M. Eustice 和 M. JohnsonRoberson. WaterGAN：一种用于实现单目水下图像实时色彩校正的无监督生成网络。*IEEE机器人与自动化快报（RA-L）* 3(1):387–394, 2018. 3

[29] P. Liu、G. Wang、H. Qi、C. Zhang、H. Zheng 和 Z. Yu。基于深度残差框架的水下图像增强。*IEEE Access*，7:94614–94629,2019。2，3

[30] R. Liu、M. Hou、X. Fan 和 Z. Luo。真实世界水下增强技术：具有挑战性、基准性和高效性的解决方案。*arXiv 预印本 arXiv: 1901.05320*，2019。6

[31] H. Lu、Y. Li 和 S. Serikawa。基于引导三角双侧滤波器与快速自动色彩校正的水下图像增强技术。收录于*IEEE国际图像处理会议*，第3412–3416页。IEEE，2013。1，3

[32] A. L. Maas、A. Y. Hannun 和 A. Y. Ng. 整流器非线性度提升神经网络声学模型。见*国际机器学习会议（ICML）*第30卷第3页，2013年。3

[33] X. Mao，Q. Li，H. Xie，R. Y. Lau，Z. Wang，和 S. Paul Smolley. 最小二乘生成对抗网络. 在*IEEE国际计算机视觉会议(ICCV)*上，第2794–2802页，2017年。2，5，7

[34] M. Mirza 和 S. Osindero。条件生成对抗网络。*arXiv 预印本 arXiv:1411.1784*，2014。3

[35] OpenROV. trident.https://www.openrov.com/，2017年。访问日期：2019年3月15日。4

[36] K. Panetta、C. Gao 和 S. Agaian. 受人类视觉系统启发的水下图像质量度量方法。*IEEE海洋工程学报*，41(3): 541–551,2016。6

[37] Z.-u. Rahman、D. J. Jobson 和 G. A. Woodell. Retinex 处理技术用于自动图像增强。*电子成像杂志*，13(1):100–111,2004。2

[38] O. Ronneberger、P. Fischer 和 T. Brox. U-Net：用于生物医学图像分割的卷积网络。收录于*国际医学图像计算与计算机辅助干预会议*，第234–241页。Springer出版社，2015年。3，4

[39] F. Shkurti, A. Xu, M. Meghjani, J. C. G. Higuera, Y. Girdhar, Giguere, 等. 使用异构机器人团队对海洋环境进行多领域监测. 在*IEEE/RSJ国际智能机器人与系统会议(IROS)*上,第1747–1753页.IEEE,2012.1

[40] W. Wang、J. Shen、X. Dong 和 A. Borji. 基于注视点预测的显著目标检测. 在*IEEE计算机视觉与模式识别会议（CVPR）*上，第1711–1720页，2018年。1，7

[41] Z. Wang, A. C. Bovik, H. R. Sheikh, E. P. Simoncelli, 等. 图像质量评估:从误差可见性到结构相似性.*IEEE图像处理汇刊*,13(4):600–612,2004.6

[42] Z. Yi、H. Zhang、P. Tan 和 M. Gong. 双GAN：图像到图像转换的无监督双学习。收录于*IEEE国际计算机视觉会议（ICCV）*，第2849–2857页，2017年。3

[43] X. Yu、Y. Qu 和 M. Hong. 水下生成对抗网络：基于条件生成对抗网络的水下图像恢复。见*国际模式识别会议*，第66–75页。Springer出版社，2018。2、3、4

[44] R. Zhang、P. Isola 和 A. A. Efros. 彩色图像着色. 在*欧洲计算机视觉会议（ECCV）*上，第649–666页。Springer出版社，2016年。2

[45] S. Zhang，T. Wang，J. Dong，和 H. Yu. 基于扩展多尺度Retinex的水下图像增强技术。*神经计算*，245:1–9, 2017。1，3

[46] J. Zhao、M. Mathieu 和 Y. LeCun. 基于能量的生成对抗网络. 2017.2

[47] J.-Y. Zhu、T. Park、P. Isola 和 A. A. Efros。基于循环一致性对抗网络的非配对图像间翻译。收录于*IEEE国际计算机视觉会议(ICCV)*，第2223–2232页，2017年。2、3、4、5、7